

大型架构及配置技术

NSD ARCHITECTURE

DAY05

内容

上午	09:00 ~ 09:30	作业讲解和回顾
	09:30 ~ 10:20	大数据
	10:30 ~ 11:20	Hadoop
	11:30 ~ 12:00	
下午	14:00 ~ 14:50	Hadoop安装与配置
	15:00 ~ 15:50	
	16:10 ~ 17:10	HDFS
	17:20 ~ 18:00	总结和答疑



大数据

 大数据介绍
 大数据的由来

 什么是大数据

 大数据特性

 大数据与Hadoop

大数据



大数据介绍



大数据的由来

大数据

随着计算机技术的发展,互联网的普及,信息的积累已经到了一个非常庞大的地步,信息的增长也在不断的加快,随着互联网、物联网建设的加快,信息更是爆炸是增长,收集、检索、统计这些信息越发困难,必须使用新的技术来解决这些问题



什么是大数据

- 大数据的定义
 - 大数据指无法在一定时间范围内用常规软件工具进行捕捉、管理和处理的数据集合,需要新处理模式才能具有更强的决策力、洞察发现力和流程优化能力的海量、高增长率和多样化的信息资产
 - 是指从各种各样类型的数据中, 快速获得有价值的信息





什么是大数据(续1)

- 大数据能做什么
 - 企业组织利用相关数据分析帮助他们降低成本、提高 效率、开发新产品、做出更明智的业务决策等
 - 把数据集合并后进行分析得出的信息和数据关系性,用来察觉商业趋势、判定研究质量、避免疾病扩散、 打击犯罪或测定即时交通路况等
 - 大规模并行处理数据库,数据挖掘电网,分布式文件系统或数据库,云计算平和可扩展的存储系统等



大数据特性







大数据特性(续1)

- 大数据的5V特性是什么?
 - (V)olume (大体量)
 可从数百TB到数十数百PB、甚至EB的规模
 - (V)ariety(多样性) 大数据包括各种格式和形态的数据
 - (V)elocity(时效性) 很多大数据需要在一定的时间限度下得到及时处理
 - (V)eracity(准确性)

 处理的结果要保证一定的准确性
 - (V)alue(大价值)

大数据包含很多深度的价值,大数据分析挖掘和利用将带来巨大的商业价值





大数据与Hadoop

- Hadoop是什么
 - Hadoop是一种分析和处理海量数据的软件平台
 - Hadoop是一款开源软件,使用JAVA开发
 - Hadoop可以提供一个分布式基础架构

- Hadoop特点
 - 高可靠性、高扩展性、高效性、高容错性、低成本



Hadoop

Hadoop历史起源 Hadoop起源 Hadoop组件 Hadoop常用组件 Hadoop核心组件 Hadoop Hadoop生态系统 HDFS结构 HDFS角色及概念 MapReduce结构 MapReduce结构及概念 Yarn结构 Yarn角色及概念



Hadoop历史起源



Hadoop起源

- 2003年开始Google陆续发表了3篇论文
 - GFS , MapReduce , BigTable
- GFS
 - GFS是一个可扩展的分布式文件系统,用于大型的、分布式 的、对大量数据进行访问的应用
 - 可以运行于廉价的普通硬件上,提供容错功能
- MapReduce
 - MapReduce是针对分布式并行计算的一套编程模型,由
 Map和Reduce组成,Map是映射,把指令分发到多个worker上,Reduce是规约,把worker计算出的结果合并





Hadoop起源(续1)

- BigTable
 - BigTable是存储结构化数据
 - BigTable建立在GFS , Scheduler , Lock Service和 MapReduce之上
 - 每个Table都是一个多维的稀疏图





Hadoop起源(续2)

- GFS、MapReduce和BigTable三大技术被称为 Google的三驾马车,虽然没有公布源码,但发布了 这三个产品的详细设计论
- Yahoo资助的Hadoop,是按照这三篇论文的开源 Java实现的,但在性能上Hadoop比Google要差很多
 - GFS - -> HDFS
 - MapReduce– > MapReduce
 - BigTable - -> Hbase





Hadoop组件



Hadoop常用组件

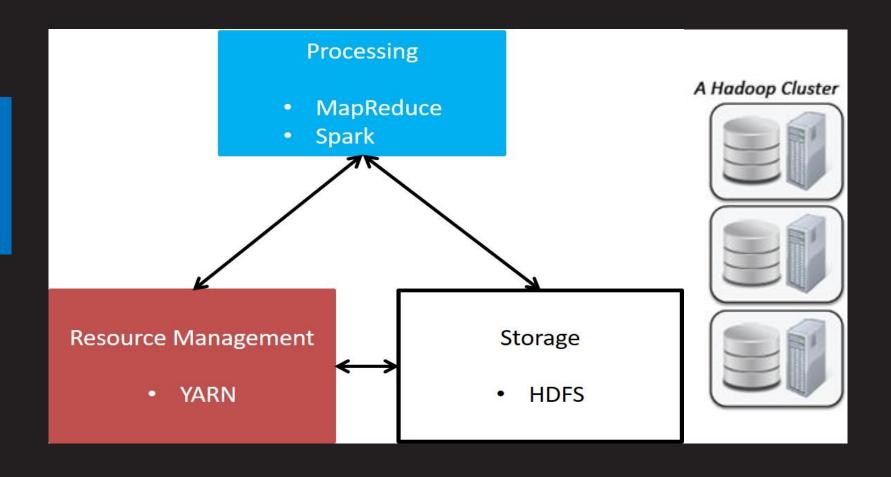
- HDFS: Hadoop分布式文件系统(核心组件)
- MapReduce:分布式计算框架(核心组件)
- Yarn:集群资源管理系统(核心组件)
- Zookeeper:分布式协作服务
- Hbase:分布式列存数据库
- Hive:基于Hadoop的数据仓库
- Sqoop:数据同步工具
- Pig:基于Hadoop的数据流系统
- Mahout:数据挖掘算法库







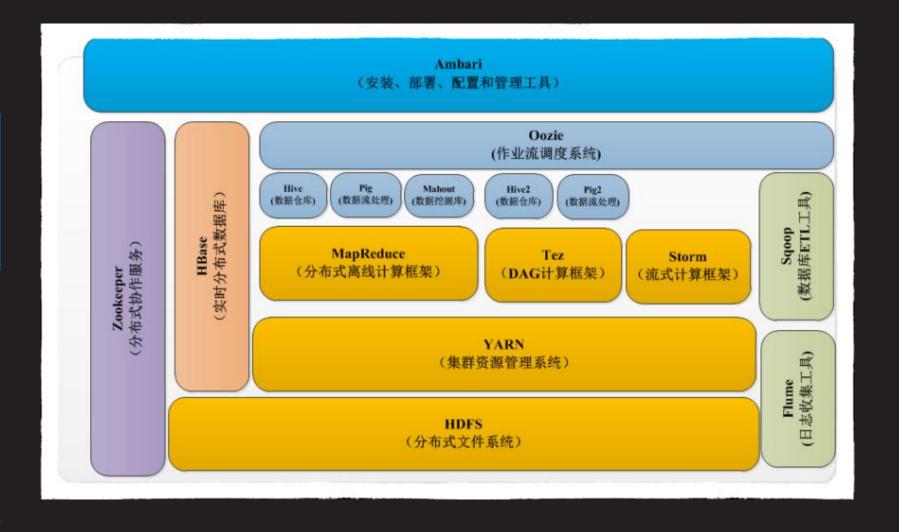
Hadoop核心组件





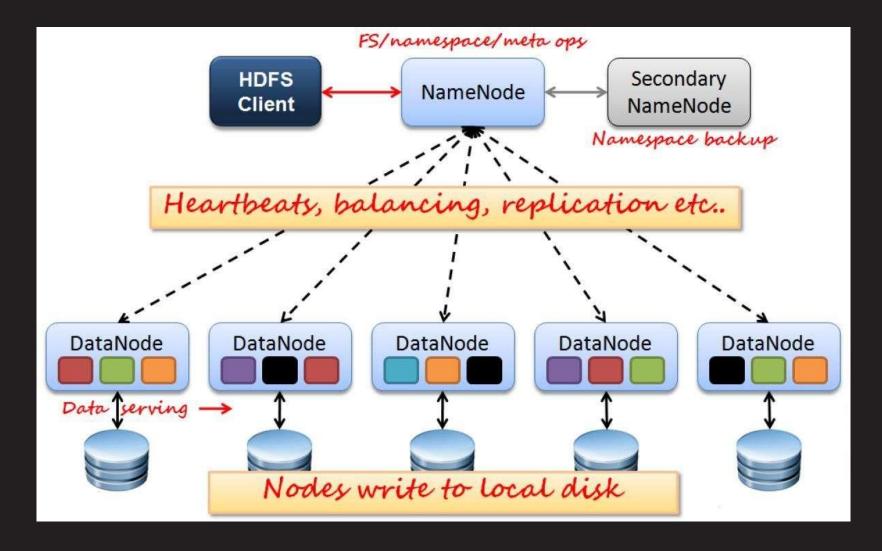


Hadoop生态系统





HDFS结构





HDFS角色及概念

Hadoop体系中数据存储管理的基础,是一个高度容错的系统,用于在低成本的通用硬件上运行

- 角色和概念
 - Client
 - Namenode
 - Secondarynode
 - Datanode





HDFS角色及概念(续1)

- NameNode
 - Master节点,管理HDFS的名称空间和数据块映射信息,配置副本策略,处理所有客户端请求

- Secondary NameNode
 - 定期合并fsimage 和fsedits , 推送给NameNode
 - 紧急情况下,可辅助恢复NameNode

• 但Secondary NameNode并非NameNode的热备





HDFS角色及概念(续2)

- DataNode
 - 数据存储节点,存储实际的数据
 - 汇报存储信息给NameNode

Client

- 切分文件
- 访问HDFS
- 与NameNode交互,获取文件位置信息
- 与DataNode交互,读取和写入数据

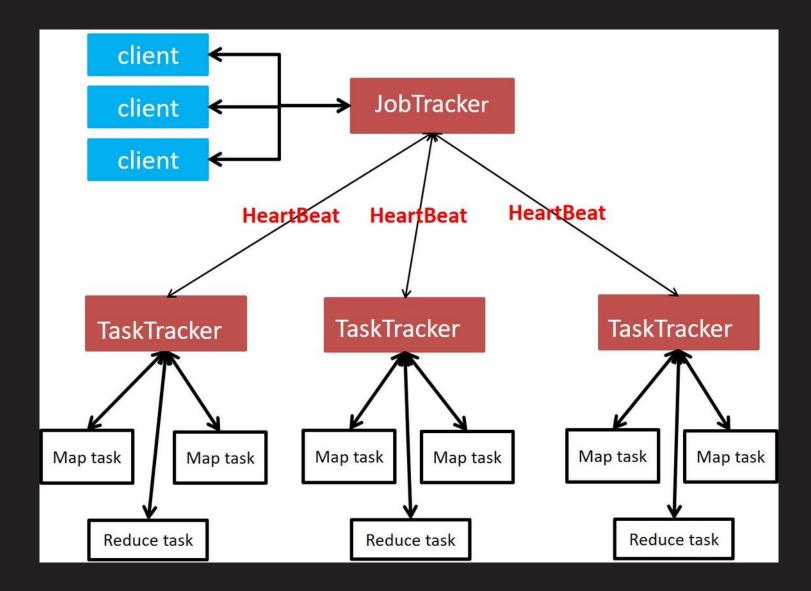


HDFS角色及概念(续3)

- Block
 - 每块缺省128MB大小
 - 每块可以多个副本



MapReduce结构







MapReduce角色及概念

源自于Google的MapReduce论文, JAVA实现的分布式计算框架

- 角色和概念
 - JobTracker
 - TaskTracker
 - Map Task
 - Reducer Task





MapReduce角色及概念(续1)

- JobTracker
 - Master节点只有一个
 - 管理所有作业/任务的监控、错误处理等
 - 将任务分解成一系列任务,并分派给TaskTracker

- TaskTracker
 - Slave节点,一般是多台
 - 运行Map Task和Reduce Task
 - 并与JobTracker交互, 汇报任务状态



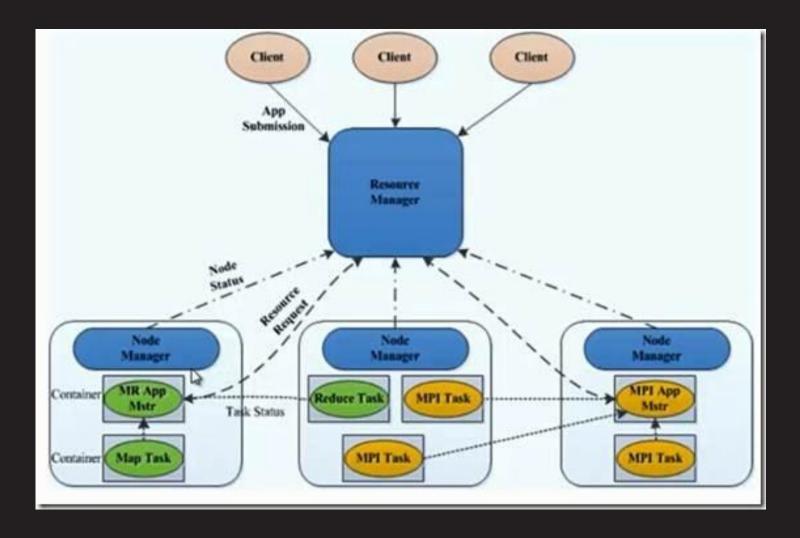


MapReduce角色及概念(续2)

- · Map Task:解析每条数据记录,传递给用户编写的 map()并执行,将输出结果写入本地磁盘
 - 如果为map-only作业,直接写入HDFS
- Reducer Task: 从Map Task的执行结果中,远程读取输入数据,对数据进行排序,将数据按照分组传递给用户编写的reduce函数执行



Yarn结构







Yarn角色及概念(续1)

• Yarn是Hadoop的一个通用的资源管理系统

- Yarn角色
 - Resourcemanager
 - Nodemanager
 - ApplicationMaster
 - Container
 - Client



Yarn角色及概念(续2)

- ResourceManager
 - 处理客户端请求
 - 启动/监控ApplicationMaster
 - 监控NodeManager
 - 资源分配与调度
- NodeManager
 - 单个节点上的资源管理
 - 处理来自ResourceManager的命令
 - 处理来自ApplicationMaster的命令





Yarn角色及概念(续3)

- Container
 - 对任务运行行环境的抽象,封装了CPU、内存等
 - 多维资源以及环境变量、启动命令等任务运行相关的信息资源分配与调度
- ApplicationMaster
 - 数据切分
 - 为应用程序申请资源,并分配给内部任务
 - 任务监控与容错





Yarn角色及概念(续4)

- Client
 - 用户与Yarn交互的客户端程序
 - 提交应用程序、监控应用程序状态, 杀死应用程序等





Yarn角色及概念(续5)

- Yarn的核心思想
- 将JobTracker和TaskTacker进行分离,它由下面几大 构成组件
 - ResourceManager一个全局的资源管理器
 - NodeManager每个节点(RM)代理
 - ApplicationMaster表示每个应用
 - 每一个ApplicationMaster有多个Container在 NodeManager上运行



Hadoop安装与配置

Hadoop介绍

Hadoop模式

单机模式

伪分布式

Hadoop配置文件及格式

Hadoop安装与配置



Hadoop介绍

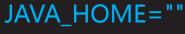
Hadoop模式

- Hadoop的部署模式有三种
 - 单机
 - 伪分布式
 - 完全分布式



单机模式

- Hadoop的单机模式安装非常简单
 - 获取软件 http://hadoop.apache.org
 - 安装配置Java环境,安装jps工具 安装Openjdk和Openjdk-devel
 - 设置环境变量,启动运行
 - hadoop-env.sh







单机模式(续1)

- Hadoop的单机模式安装很简单,只需配置好环境变量即 可运行,这个模式一般用来学习和测试Hadoop的功能
 - 测试 --- 统计词频

```
# cd /usr/local/hadoop
# mkdir input
# cp *.txt input/
# ./bin/hadoop jar ./share/hadoop/mapreduce/hadoop-mapreduce-
examples-2.7.3.jar wordcount input output
```





案例1:安装Hadoop

- 1. 单机模式安装Hadoop
- 2. 安装JAVA环境
- 3. 设置环境变量,启动运行



伪分布式

- 伪分布式

 - 伪分布式的配置和完全分布式配置类似





Hadoop配置文件及格式

- 文件格式
 - Hadoop-env.sh

```
JAVA_HOME
HADOOP_CONF_DIR
```

- xml文件配置格式



HDFS

HDFS分布式文件系统

完全分布式

搭建完全分布式

课程知识点总结

HDFS



HDFS分布式文件系统

完全分布式

• 系统规划

主机	角色	软件
192.168.1.21 Nn01	NameNode SecondaryNameNode	HDFS
192.168.1.22 Node1	DataNode	HDFS
192.168.1.23 Node2	DataNode	HDFS
192.168.1.24 node3	DataNode	HDFS



搭建完全分布式

- 基础环境准备
 - 新开启3台虚拟机
 - 禁用 selinuxSELINUX=disabled
 - 禁用 firewalld# systemctl stop firewalld# systemctl mask firewalld
 - 安装 java-1.8.0-openjdk-devel

yum install -y java-1.8.0-openjdk-devel





搭建完全分布式(续1)

- 基础环境准备
 - 在3台机器上配置/etc/hosts
 - 注意:所有主机都能ping通namenode的主机名,namenode能ping通所有节点
 - java -version 验证java安装
 - jps 验证角色





搭建完全分布式(续2)

- 配置SSH信任关系(NameNode)
 - 注意:不能出现要求输入yes的情况,每台机器都要能 <u>登录成功,包括本机!!!</u>
 - ssh_configStrictHostKeyChecking no

```
# ssh-keygen -b 2048 -t rsa -N " -f key
# ssh-copy-id -i ./key.pub root@ip.xx.xx.xx
```





搭建完全分布式(续3)

HDFS完全分布式系统配置

- 环境配置文件: hadoop-env.sh

- 核心配置文件: core-site.xml

- HDFS配置文件: hdfs-site.xml

- 节点配置文件:slaves





搭建完全分布式(续4)

- 环境配置文件hadoop-env.sh
 - OpenJDK的安装目录: JAVA_HOME
 - Hadoop配置文件的存放目录: HADOOP_CONF_DIR





搭建完全分布式(续5)

- 核心配置文件 core-site.xml
 - fs.defaultFS:文件系统配置参数
 - hadoop.tmp.dir:数据目录配置参数





搭建完全分布式(续6)

- HDFS配置文件hdfs-site.xml
 - Namenode: 地址声明 dfs.namenode.http-address
 - Secondarynamenode: 地址声明 dfs.namenode.secondary.http-address
 - 文件冗余份数 dfs.replication





搭建完全分布式(续7)

HDFS配置文件hdfs-site.xml

```
cproperty>
    <name>dfs.namenode.http-address</name>
    <value>nn01:50070</value>
  </property>
  cproperty>
    <name>dfs.namenode.secondary.http-
address</name>
    <value>nn01:50090</value>
  </property>
  cproperty>
    <name>dfs.replication</name>
    <value>2</value>
  </property>
```





搭建完全分布式(续8)

- 节点配置文件slaves
 - 只写DataNode节点的主机名称

node1

node2

node3

- 同步配置
- Hadoop所有节点的配置参数完全一样,在一台配置好后,把配置文件同步到其它所有主机上





搭建完全分布式(续9)

- · HDFS完全分布式配置
 - 在所有机器上创建/var/hadoop文件夹# mkdir /var/hadoop
 - 在namenode上执行格式化操作# ./bin/hdfs namenode -format
 - 启动集群
 - # ./sbin/start-dfs.sh





搭建完全分布式(续10)

- JPS验证角色
 - NameNode验证

[root@nn01 hadoop]# jps 29826 SecondaryNameNode 31237 Jps 29643 NameNode

– DataNode验证

[root@node1 ~]# jps 24472 Jps 24027 DataNode





搭建完全分布式(续11)

- 节点验证
 - NameNode上
 - bin/hdfs dfsadmin -report

[root@nn01 hadoop]# bin/hdfs dfsadmin -report Configured Capacity: 51505004544 (47.97 GB)

DFS Used: 733184 (716 KB)

...

Missing blocks: 0

Missing blocks (with replication factor 1): 0

Live datanodes (3):





案例2:安装配置Hadoop

- 1. 另备三台虚拟机,安装Hadoop
- 2. 使所有节点能够ping通,配置SSH信任关系
- 3. 节点验证



课程知识点总结

- 大数据的5V特性
 - (V)olume (大体量)
 - (V)ariety(多样性)
 - (V)elocity(时效性)
 - (V)eracity(准确性)
 - (V)alue(大价值)





课程知识点总结(续1)

- Hadoop是用什么语言开发的
 - JAVA
- Hadoop的三大核心组件
 - Hdfs
 - MapReduce
 - Yarn





课程知识点总结(续2)

- Hadoop有几种部署模式
 - 单机
 - 伪分布式
 - 完全分布式
- 列举5种Hadoop的常见组件



总结和答疑

同步数据出错

问题现象

故障分析及排除

总结和答疑



同步数据出错



问题现象

• rsync同步数据不成功

bash: rsync: command not found

rsync: connection unexpectedly closed (0 bytes received so far)

[sender]

rsync error: remote command not found (code 127) at io.c(226)

[sender=3.1.2]





故障分析及排除

- 原因分析
 - 要同步数据的主机没有安装rsync
- 解决方案
 - 安装rsync

